MESTRADO EM ENGENHARIA BIOMÉDICA
2025/2026

Processamento de Linguagem Natural

EXTRAÇÃO E INTEGRAÇÃO DE INFORMAÇÃO MÉDICA COM INTERFACE WEB

Ana Beatriz Zeferino (PG59852)
Daniela Coelho (PG59872)
Daniela Rodrigues (PG59757)

INTRODUÇÃO

Desenvolvimento de um sistema para processar documentos não estruturados (PDF) e transformá-los em informação organizada.
Criação de ficheiros JSON estruturados para suporte a uma interface *web* interativa de consulta.

SISTEMA CAPAZ DE PROCESSAR DOCUMENTOS PDF

EXTRAÇÃO DE INFORMAÇÃO RELEVANTE

CONVERSÃO PARA UM FORMATO ESTRUTURADO

DOCUMENTOS ANALISADOS

{medicina.pdf}

Glossário terminológico médico em galego, com traduções para espanhol, inglês, português e latim;

{diccionari-multilinguee-de-la-covid-19.pdf}

Vocabulário especializado sobre COVID-19 em catalão, com equivalentes terminológicos em várias línguas europeias;

{glossario_enfermagem.pdf}

Glossário de termos de enfermagem em português;

{glossario_termos_medicos.pdf}

Glossário de termos médicos técnicos e populares em português.

METODOLOGIA

- Conversão dos ficheiros em formato não estruturado (PDF) para o respetivo formato de interesse (TXT e XML);
- Leitura dos ficheiros;
- Limpeza incluindo remoção que quebras de páginas, cabeçalhos;
- Identificação das entradas;
- Extração dos campos necessários;
- Construção e definição da estrutura de dados;
- Exportação para um ficheiro JSON;

UNIFICAÇÃO DOS DADOS

Para integrar os diferentes **ficheiros JSON** produzidos a partir das várias, foi desenvolvido o script ***unificar.py*** com o objetivo de normalizar campos, reorganizar informação e converter formatos distintos numa estrutura comum.

Leitura dos ficheiros **JSON individuais**, extração de elementos e transformação para um **estrutura uniforme**.

Criação de um dicionário final consolidado com toda a informação ***dicionario_unificado.json***

FORMATO DO DICIONÁRIO

```
{
    "termo_galego": {
      "palavra": "abdome",
      "genero_palavra": "m",
      "sinonimos_galego": [
        "rexión abdominal (f)",
        "panza [pop.]"
      ]
    },
    "tema": [
      "Anatomía"
    ],
    "traducoes": {
      "espanhol": "abdomen ; panza [pop.],
      "inglês": "abdominal region ; gut [pop.]",
      "português": "abdome; abdômen,
      "latim": "abdomen"
    },
    "definição": "Região corporal | barriga, ventre"
  },
```

- "palavra": "abdome" → Forma principal do termo em galego
- "genero_palavra": "m" → Gênero gramatical da palavra
- "sinonimos_galego" → Lista de sinónimos em galego
- "tema" → Lista de temas associados ao termo
- "traducoes" → Traduções do termo nas diferentes linguas
- "definição" → Definição integrada dos glossários em português

INTERFACE WEB

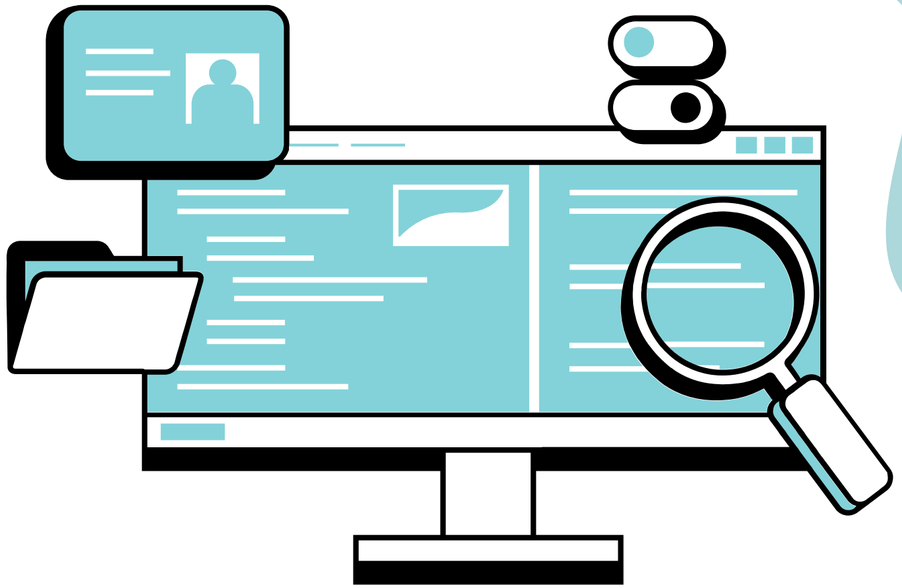

Desenvolvimento de uma aplicação web em ***Python*** utilizando o ***microframework Flask***.

Camada de apresentação apresentação construída com ***HTML*** e o motor de templates ***Jinja2***.

INTERFACE WEB

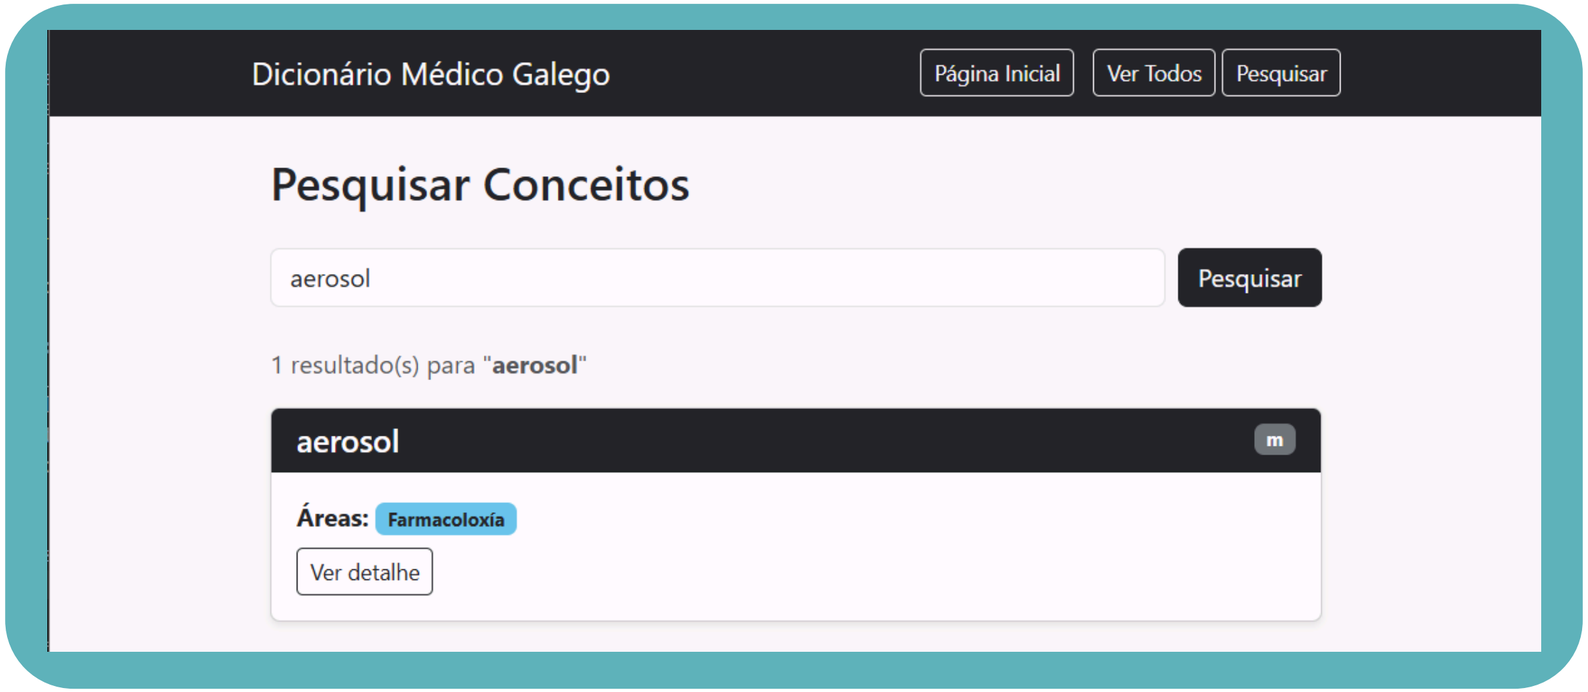

INTERFACE WEB

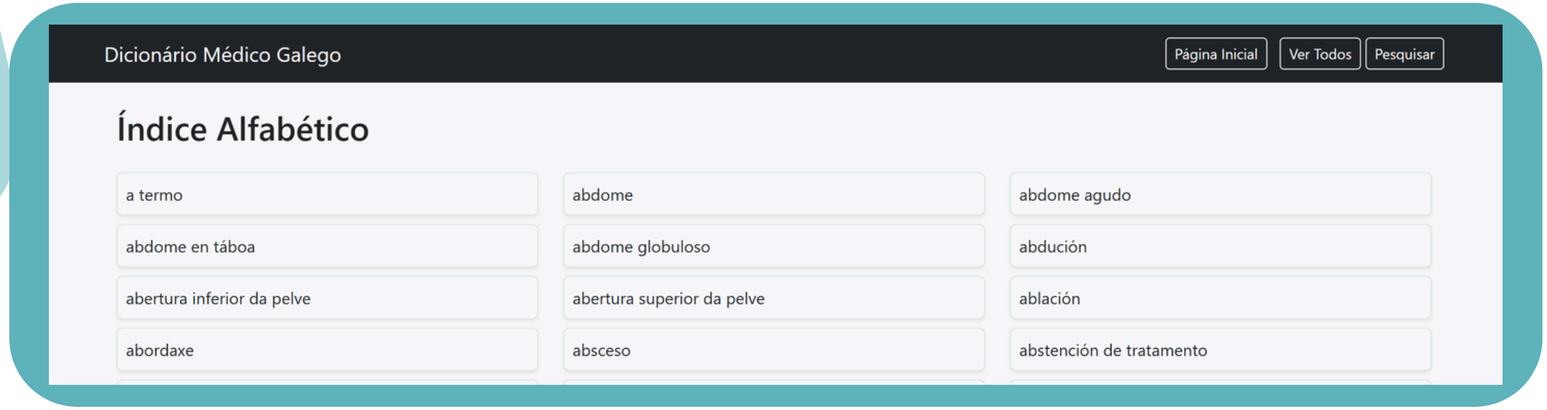

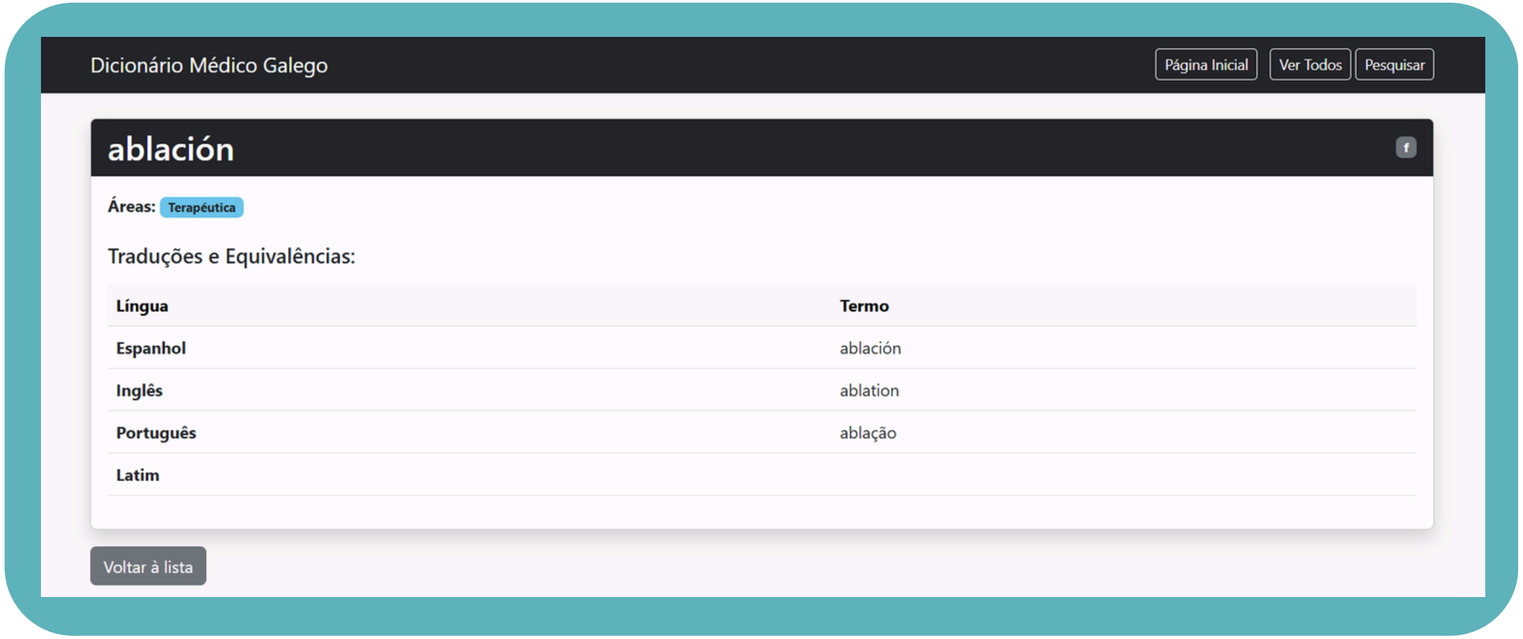

MESTRADO EM ENGENHARIA BIOMÉDICA
2025/2026

Processamento de Linguagem Natural

EXTRAÇÃO E INTEGRAÇÃO DE INFORMAÇÃO MÉDICA COM INTERFACE WEB

Ana Beatriz Zeferino (PG59852)
Daniela Coelho (PG59872)
Daniela Rodrigues (PG59757)