Universidade do Minho

Processamento de Linguagem Natural

Trabalho Prático em Grupo
Extração e Integração de Informação Médica com Interface Web

Grupo 3

Ana Beatriz Zeferino (pg59852)

Daniela Coelho (pg59872)

Daniela Rodrigues (pg59757)

Braga, abril de 2026

Resumo

O presente relatório descreve o desenvolvimento de um sistema de extração e organização de informação terminológica a partir de vários dicionários médicos em formato PDF, no âmbito da unidade curricular de Processamento de Linguagem Natural em Engenharia Biomédica. O trabalho envolveu a análise detalhada dos documentos, a identificação das suas estruturas internas e a implementação de métodos de processamento adaptados às particularidades de cada um.

Após a conversão, limpeza e normalização do texto, a informação relevante foi estruturada em formato JSON, garantindo consistência entre entradas provenientes de fontes distintas. Esta representação comum permitiu unificar os quatro glossários num único dicionário terminológico.

Como etapa final, foi desenvolvida uma aplicação *web* em `Flask` que disponibiliza o dicionário através de uma interface simples e intuitiva, permitindo consultar termos, traduções e notas associadas.

Índice

1 Introdução **1**

2 Análise dos Documentos **3**

2.1 `medicina.pdf` 3

2.1.1 Estrutura das entradas 3

2.1.2 Características relevantes do documento 3

2.2 `diccionari-multilinguee-de-la-covid-19.pdf` 4

2.2.1 Tipos de entradas 4

2.2.2 Características relevantes do documento 5

2.3 `glossario_enfermagem.pdf` 6

2.3.1 Estrutura das entradas 6

2.3.2 Características relevantes do documento 6

2.4 `glossario_termos_medicos.pdf` 7

2.4.1 Estrutura das entradas 7

2.4.2 Características relevantes do documento 7

3 Processamento do texto **9**

3.1 `medicina.py` 9

3.2 `dicionario_covid.py` 10

3.3 `glossario_enfermagem.py` 12

3.4 `glossario_termos_medicos.py` 13

4 Análise e definição da estrutura JSON **15**

4.1 Estruturas JSON individuais 15

4.1.1 Estrutura JSON do `medicina.pdf` 15

4.1.2 Estrutura JSON do `diccionari-multilinguee-de-la-covid-19.pdf` 16

4.1.3 Estrutura JSON do `glossario_enfermagem.pdf` 17

4.1.4 Estrutura JSON do `glossario_termos_medicos.pdf` 17

4.2 Heterogeneidade estrutural dos dados 18

4.3 Processo de unificação dos dados (`unificar.py`) 18

4.4 Estrutura do dicionário unificado final (`dicionario_unificado.json`) 19

5 Desafios encontrados e soluções **20**

6 Aplicação Web **22**

6.1 Arquitetura geral 22

6.2 Estrutura do ficheiro `app.py` 22

6.2.1 Carregamento do dicionário 22

6.2.2 Rotas principais 22

6.2.3 Página de consulta do conceito 23

6.2.4 Sistema de pesquisa 23

6.3 Templates HTML 23

6.3.1 Template `layout.html` 24

6.3.2 Template `home.html` 24

6.3.3 Template `conceitos.html` 24

6.3.4 Template `conceito.html` 24

6.3.5 Template `pesquisar.html` 24

7 Conclusão **25**

Lista de Figuras

1 Estrutura de cada entrada do `diccionari-multilinguee-de-la-covid-19.pdf` 5

1 Introdução

Nas últimas décadas, a quantidade de informação clínica e biomédica disponível em formato digital tem crescido de forma exponencial. Registos médicos, publicações científicas, manuais de procedimentos e glossários terminológicos constituem uma vasta riqueza de conhecimento que, na sua maioria, se encontra armazenada em formato não estruturado, frequentemente sob a forma de ficheiros PDF. A extração automática de informação a partir destes documentos representa, por isso, um desafio central entre o Processamento de Linguagem Natural (PLN) e a Engenharia Biomédica [1].

No âmbito desta unidade curricular, foi proposto o desenvolvimento de um sistema capaz de processar documentos PDF de domínio médico, extraindo informação relevante e convertendo-a para um formato estruturado.

Este tipo de sistema tem aplicações práticas diretas na construção de bases de conhecimento, no suporte a sistemas de recuperação de informação e na alimentação de modelos de linguagem especializados em medicina.

O presente trabalho envolveu o processamento dos seguintes documentos:

- `medicina.pdf`: glossário terminológico médico em galego, com traduções para espanhol, inglês, português e latim;
- `diccionari-multilinguee-de-la-covid-19.pdf`: vocabulário especializado sobre COVID-19 em catalão, com equivalentes terminológicos em várias línguas europeias;
- `glossario_enfermagem.pdf`: glossário de termos de enfermagem em português;
- `glossario_termos_medicos.pdf`: glossário de termos médicos técnicos e populares em português.

Cada documento apresenta características distintas, o que exigiu a implementação de *parsers* específicos e estratégias de extração adaptadas ao respetivo conteúdo. Após a conversão, limpeza e normalização dos dados, a informação extraída foi organizada em ficheiros JSON e, posteriormente num só ficheiro JSON unificado, seguindo uma estrutura comum definida pelo grupo, de forma a garantir consistência entre os termos provenientes de fontes distintas.

Como etapa final, desenvolveu-se uma aplicação *web* baseada no *framework* `Flask`, que permite consultar o glossário final através de uma interface simples e interativa. Esta aplicação disponibiliza um índice alfabético de termos e páginas de consulta de conceitos com traduções e notas.

2 Análise dos Documentos

2.1 `medicina.pdf`

O documento `medicina.pdf` é um glossário de termos médicos em galego. Cada entrada apresenta informação linguística essencial, podendo incluir género gramatical, área em que o termo se enquadra, sinónimos e traduções para espanhol, inglês, português e latim. Apesar de ser relativamente organizado, o documento contém detalhes que exigem um processamento cuidadoso no momento de extrair automaticamente os dados.

2.1.1 Estrutura das entradas

Cada entrada do glossário segue um padrão relativamente consistente, contendo:

- o número identificador da entrada;
- o termo em galego e o respetivo género (m, f ou a);
- uma ou mais áreas temáticas associadas;
- sinónimos introduzidos pela marca `SIN.-`;
- traduções para espanhol, inglês, português e latim;
- uma nota explicativa opcional.

2.1.2 Características relevantes do documento

Apesar da organização relativamente consistente, o documento apresenta algumas características que influenciam o processamento posterior:

- **Quebras de linha frequentes**: alguns campos estendem-se por várias linhas, especialmente notas.
- **Variações subtis na formatação**: pequenas diferenças na forma como sinónimos e traduções são apresentados.
- **Elementos distribuídos em blocos**: a informação de cada entrada pode surgir separada por espaços ou quebras de página.

Estas características são típicas de documentos PDF e justificam a necessidade de uma fase de processamento e normalização, descrita na secção seguinte (3.1).

2.2 `diccionari-multilinguee-de-la-covid-19.pdf`

O *Diccionari multilingüe de la COVID-19* é um dicionário que reúne conceitos relacionados com a pandemia da COVID-19, abrangendo diversas temáticas como epidemiologia, clínica, diagnóstico, prevenção e saúde pública. O documento apresenta equivalentes terminológicos em várias línguas, incluindo occitano, basco, galego, castelhano, inglês, francês, português (PT/BR), neerlandês e árabe, tendo o catalão como língua base.

O documento encontra-se organizado por ordem alfabética e, apesar da sua estrutura clara, apresenta alguns desafios no processo de limpeza e extração de informação, devido à diversidade de línguas envolvidas.

2.2.1 Tipos de entradas

Cada entrada deste dicionário segue uma estrutura padronizada que inclui:

- **o índice númerico**;
- **a denominação em catalão** acompanhada da respetiva categoria lexical (como nome, adjetivo, verbo, por exemplo);
- **sinónimos em catalão**, podendo incluir:
  - sinónimos absolutos (`sin.`);
  - sinónimos complementares (`sin. compl.`);
  - siglas ou denominações comerciais.
- **equivalentes noutras línguas**, cada um acompanhado da respetiva categoria lexical;
- **área temática**: associada ao conceito;
- **referências cruzadas**,: frequentemente introduzidas pela marca `veg.` (que significa "veja" em português);
- **notas explicativas**: de caráter técnico ou contextual.

A figura 1 facilita a compreensão da estrutura da informação descrita anteriormente.

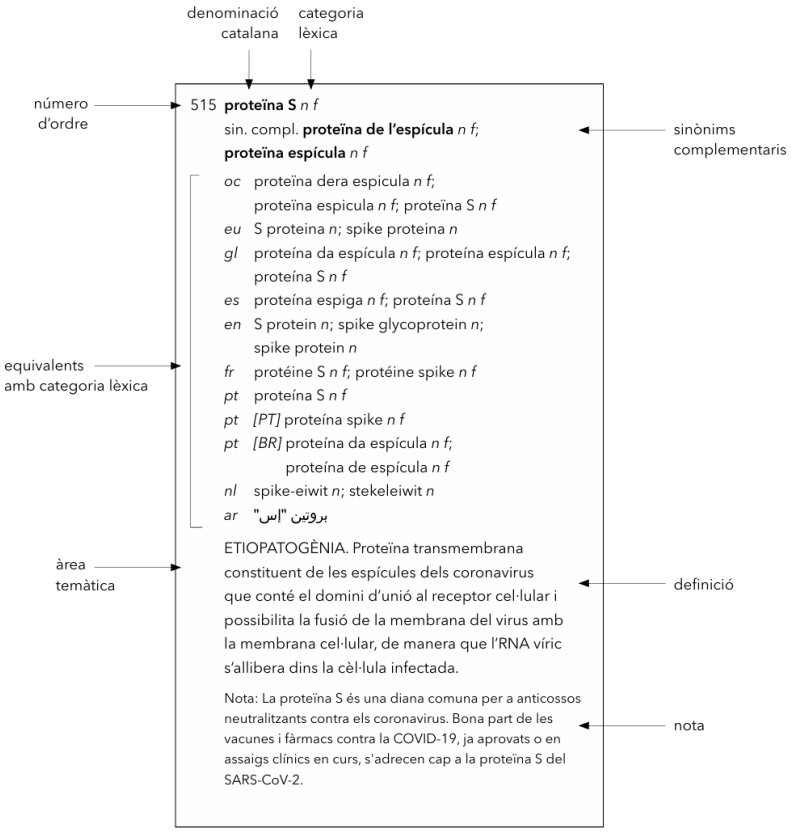

Figura 1: Estrutura de cada entrada do `diccionari-multilinguee-de-la-covid-19.pdf`

2.2.2 Características relevantes do documento

O documento apresenta várias características que influenciam o processamento realizado posteriormente:

- **Multilinguismo extensivo**: cada entrada pode conter equivalentes em mais de dez línguas, com diferentes alfabetos e convenções ortográficas.
- **Presença de múltiplos sinónimos**: alguns conceitos incluem várias denominações catalãs, com distinção entre tipos de sinonímia.
- **Referências cruzadas frequentes**: a marca `veg.` remete para outras entradas, criando relações que devem ser preservadas.
- **Notas longas e detalhadas**: algumas entradas incluem explicações extensas, frequentemente distribuídas por várias linhas.

2.3 `glossario_enfermagem.pdf`

O documento `glossario_enfermagem.pdf` corresponde a um glossário de termos utilizados na prática de enfermagem que reúne conceitos técnicos frequentemente usados em contexto clínico, bem como algumas designações alternativas ou formas populares associadas a determinados termos.

Ao contrário de outros documentos analisados, este glossário apresenta uma estrutura simples e direta, sem informação multilingue, categorias lexicais ou áreas temáticas.

2.3.1 Estrutura das entradas

Cada entrada do glossário segue um padrão relativamente uniforme, contendo:

- **o termo principal**: geralmente apresentado em português;
- **uma definição**: clara e concisa, descrevendo o significado do termo no contexto da enfermagem;
- **designações alternativas ou sinónimos**: que, quando presentes, podem incluir formas populares ou variantes terminológicas.

As entradas são apresentadas de forma sequencial, sem numeração explícita e sem subdivisões internas, o que contribui para a simplicidade do documento.

2.3.2 Características relevantes do documento

Apesar da sua estrutura simples, o glossário apresenta algumas características que influenciam o seu processamento:

- **Ausência de marcação formal entre campos**: o termo e a definição surgem frequentemente na mesma linha ou separados apenas por pontuação, exigindo uma identificação cuidadosa dos limites de cada elemento.
- **Variação na extensão das definições**: algumas são muito curtas, enquanto outras incluem explicações mais detalhadas.
- **Presença ocasional de sinónimos**: nem todas as entradas apresentam sinónimos, e quando surgem podem estar integrados na própria definição.

Estas características tornam o documento mais fácil de interpretar, mas ainda assim, requerem uma fase de normalização para garantir consistência na estrutura final das entradas.

2.4 `glossario_termos_medicos.pdf`

O documento `glossario_termos_medicos.pdf` corresponde a um glossário de termos médicos em português, reunindo definições simples e diretas de conceitos utilizados na prática clínica. Este recurso apresenta, para muitos termos, a distinção entre a designação técnica e a forma popular, permitindo compreender tanto a terminologia científica como o vocabulário frequentemente utilizado pelos utentes.

Tal como o `glossario_enfermagem.pdf`, este documento apresenta uma estrutura linear e pouco complexa, sem categorias lexicais, áreas temáticas ou informação multilingue.

2.4.1 Estrutura das entradas

Cada entrada do glossário segue um formato relativamente uniforme, composto por:

- **o termo técnico**: apresentado como a forma principal da entrada;
- **a forma popular ou equivalente informal**: quando existe, é geralmente indicada entre parênteses ou separada por pontuação;
- **uma definição**: que descreve de forma breve o significado do termo no contexto médico.

À semelhança do `glossario_enfermagem.pdf`, entradas também surgem de forma sequencial, sem numeração explícita e sem subdivisões internas, o que reflete a simplicidade do documento.

2.4.2 Características relevantes do documento

Apesar de ser um glossário simples, o documento apresenta algumas características que influenciam o processamento posterior:

- **Variação na apresentação das formas populares**: podem surgir entre parênteses, depois de um hífen ou dentro da própria definição.
- **Definições de extensão variável**: algumas entradas são extremamente curtas, enquanto outras incluem explicações mais detalhadas.
- **Ausência de marcação formal entre campos**: o termo técnico, a forma popular e a definição podem aparecer na mesma linha, exigindo uma separação cuidadosa.

3 Processamento do texto

Nas subsecções que se seguem será apresentado, de forma detalhada, o processamento efetuado para cada um dos documentos em análise.

3.1 `medicina.py`

O processamento do ficheiro `medicina.pdf` teve como objetivo transformar o glossário médico em galego num conjunto de entradas estruturadas e organizadas num ficheiro JSON. Para isso, o documento foi convertido para XML e posteriormente analisado com recurso à biblioteca *BeautifulSoup*.

1. **Conversão do documento para XML**: O ficheiro PDF foi convertido para XML, com recurso ao comando `pdftohtml -xml -f 20 -l 543 medicina.pdf medicina.xml`, permitindo representar cada fragmento de texto como um elemento `<text>` com informação associada.

2. **Leitura e varrimento das `<text>`**: O XML foi lido em *Python* com a biblioteca *BeautifulSoup*, sendo extraído o conteúdo de cada elemento e analisado para distinguir os diferentes tipos de informação presentes no glossário.

3. **Identificação das entradas**: As entradas foram identificadas através de um padrão consistente que inclui o número da entrada, o termo em galego e o respetivo género. Sempre que este padrão surgia, iniciava-se uma nova entrada, armazenando:
   - o número identificador;
   - o termo em galego;
   - o género gramatical.

4. **Preenchimento dos campos da entrada**: As linhas seguintes até ao início da entrada seguinte foram analisadas para completar os restantes campos:
   - **Tema**: linhas correspondentes às áreas temáticas associadas ao termo;
   - **Sinónimos**: linhas iniciadas por `SIN.-`, divididas e organizadas numa lista;
   - **Nota**: linhas iniciadas por `Nota.-` ;

- **Traduções**: blocos de texto associados a cada língua, identificados pelos respetivos códigos (`es`, `en`, `pt`, `la`).

5. **Construção da estrutura de vocabulário**: Para cada entrada foi criado um dicionário *Python* contendo:
   - `termo_galego`: informação sobre o termo e sinónimos;
   - `tema`: lista de áreas temáticas;
   - `traducoes`: dicionário com equivalentes noutras línguas;
   - `nota`: quando existente.

6. **Exportação para JSON**: Todas as entradas foram agregadas numa lista e guardadas num dicionário com a chave `"Vocabulário médico"`, sendo o resultado exportado para `medicina.json`.

3.2 `dicionario_covid.py`

O processamento do `diccionari-multilinguee-de-la-covid-19.pdf` teve como objetivo transformar o dicionário terminológico multilingue num conjunto de entradas estruturadas, permitindo organizar informação complexa, distribuída por várias línguas, sinónimos e referências, num formato JSON uniforme.

1. **Conversão do documento para texto**: O ficheiro PDF foi convertido para texto simples, com o comando `pdftotext -f 30 -l 182 -raw -nopgbrk diccionari-multilinguee-de-la-covid-19.pdf dicionario_covid.txt` que permitiu controlar o intervalo de páginas a extrair, preservar a ordem original dos elementos textuais e evitar a inserção automática de quebras de página, produzindo um bloco de texto contínuo.

2. **Limpeza inicial do texto**: Foram removidas quebras de página (\f), cabeçalhos recorrentes do documento, letras isoladas resultantes da extração e números de página. Foram também eliminadas linhas vazias consecutivas, produzindo um bloco de texto mais limpo e adequado à segmentação posterior.

3. **Segmentação das entradas**: As entradas foram separadas através de uma expressão regular que identifica linhas iniciadas por um número seguido de um termo. Cada ocorrência deste padrão marca o início de uma nova entrada, permitindo dividir o texto em blocos independentes.

4. **Extração do termo principal**: Em cada bloco, a primeira linha contém o número da entrada e a denominação em catalão. O código extraiu ambos os elementos, removendo marcas residuais como indicações de género (`n m`, `n f`, etc.), de modo a obter o termo principal limpo.

5. **Identificação e extração dos campos**: As linhas seguintes foram analisadas para identificar diferentes tipos de informação:

   - **Categoria temática**: detetada quando o bloco contém uma das etiquetas presentes no documento (por exemplo, `CLÍNICA.`, `EPIDEMIOLOGIA.`, `DIAGNÒSTIC.`).
   - **Definição**: quando existe categoria, o texto que vem imediatamente a seguir até à próxima secção ou nota é extraído como definição.
   - **Traduções**: linhas iniciadas por códigos linguísticos (como `es`, `en`, `pt`, `fr`, entre outros) são processadas e normalizadas, removendo marcas gramaticais e pontuação irrelevante. De notar que, pela dificuldade em processar os caractéres, o grupo optou por excluir as traduções para árabe.

6. **Tratamento de entradas com referências**: Entradas que contêm a marca `veg.` foram ignoradas, uma vez que correspondem apenas a referências internas e não apresentam conteúdo terminológico próprio.

7. **Construção da estrutura de dados**: Para cada entrada válida foi criado um dicionário Python contendo:

   - o número identificador;
   - o termo catalão;
   - as traduções disponíveis;
   - a categoria temática e a definição (quando presentes).

8. **Exportação para JSON**: As entradas foram agregadas num dicionário global e exportadas para o ficheiro `dicionario_covid.json`, com indentação e preservação de acentos.

3.3 `glossario_enfermagem.py`

O processamento do `glossario_enfermagem.pdf` teve como objetivo transformar um conjunto de termos e definições utilizados na prática de enfermagem num formato estruturado e uniforme. O documento apresenta uma organização simples, composta por entradas independentes constituídas por um termo principal e a respetiva definição, podendo incluir sinónimos ou designações alternativas.

1. **Conversão do documento para XML**: O ficheiro PDF foi convertido para um ficheiro em formato XML, através do comando `pdftohtml -xml glossario_enfermagem.pdf glossario_enfermagem.xml`, permitindo expor cada elemento textual como uma `<text>` com atributos próprios. Esta conversão facilitou a identificação do termo principal e da respetiva definição através da análise da estrutura interna do documento.

2. **Limpeza inicial do texto**: Foram removidas quebras de linha desnecessárias, espaços indesejados e outras irregularidades resultantes da extração, garantindo que cada entrada surgia de forma clara e separada.

3. **Segmentação das entradas**: O texto foi dividido em blocos correspondentes a entradas individuais, com base na deteção de padrões estruturais simples, como linhas vazias ou separadores consistentes entre termos.

4. **Extração do termo principal**: Em cada bloco, a primeira linha foi interpretada como o termo principal da entrada. Este termo foi limpo e normalizado, removendo espaços adicionais ou marcas residuais.

5. **Extração da definição e de sinónimos**: As linhas seguintes foram analisadas para identificar:

   - **a definição**: geralmente apresentada como texto contínuo imediatamente após o termo;

- **sinónimos ou designações alternativas**: quando presentes, foram extraídos e organizados numa lista.

6. **Construção da estrutura de dados**: Para cada entrada foi criado um dicionário Python contendo:
   - o termo principal;
   - a definição associada;
   - sinónimos ou variantes terminológicas (quando existentes).

7. **Exportação para JSON**: Todas as entradas foram agregadas numa lista e exportadas para o ficheiro `glossario_enfermagem.json`, garantindo uma estrutura uniforme e preservando os caracteres acentuados.

3.4 `glossario_termos_medicos.py`

O processamento do `glossario_termos_medicos.pdf` teve como objetivo transformar um conjunto de termos médicos e respetivas definições num formato estruturado. Tal como noutros dicionários analisados, o documento apresenta uma organização simples, composta por entradas independentes constituídas por um termo principal e a sua definição, podendo incluir sinónimos ou variantes terminológicas.

1. **Conversão do documento para XML**: O ficheiro PDF foi convertido para XML através do comando `pdftohtml -xml glossario_termos_medicos.pdf glossario_termos_medicos.xml`, permitindo representar cada fragmento textual como uma `<text>` com atributos próprios. Esta estrutura facilitou a identificação dos termos e das definições através da análise dos padrões de formatação.

2. **Limpeza inicial do texto**: Foram removidas linhas vazias, espaços indesejados e outros elementos residuais da extração, garantindo que cada entrada surgia de forma clara e separada no XML.

3. **Segmentação das entradas**: As `<text>` foram percorridas sequencialmente e agrupadas em blocos correspondentes a entradas individuais. A segmentação

baseou-se na deteção de padrões consistentes de formatação, nomeadamente diferenças no atributo `font` entre termos e definições.

4. **Extração do termo principal**: Em cada bloco, o termo principal foi identificado a partir das `<text>` com o estilo característico dos títulos (por exemplo, um valor específico do atributo `font`). O termo foi limpo e normalizado, removendo espaços adicionais ou marcas residuais.

5. **Extração da definição e de sinónimos**: As `<text>` seguintes foram analisadas para identificar:

   - **a definição**: geralmente apresentada como texto contínuo logo após o termo;
   - **sinónimos ou variantes**: quando presentes, foram extraídos e organizados numa lista.

6. **Construção da estrutura de dados**: Para cada entrada foi criado um dicionário Python contendo:

   - o termo principal;
   - a definição associada;
   - sinónimos ou variantes terminológicas (quando existentes).

7. **Exportação para JSON**: Todas as entradas foram agregadas numa lista e exportadas para o ficheiro `glossario_termos_medicos.json`, garantindo uma estrutura uniforme e preservando os caracteres acentuados.

4 Análise e definição da estrutura JSON

4.1 Estruturas JSON individuais

4.1.1 Estrutura JSON do `medicina.pdf`

O ficheiro `medicina.json` resulta do processamento do dicionário médico galego, onde cada entrada corresponde a um termo em galego, acompanhado de informação linguística, temática e tradutória. Todas as entradas encontram-se agrupadas numa lista sob a chave `"Vocabulário médico"`.

A estrutura geral de cada entrada é a seguinte:

```
{
    "Vocabulário médico": [
        {
            "termo_galego": {
                "palavra": forma principal do termo,
                "genero_palavra": "género gramatical ('m', 'f', 'a')",
                "sinonimos_galego": [
                    "lista de sinónimos ou variantes, quando presentes"
                ]
            },
            "tema": ["área ou lista de áreas temáticas associadas ao termo"],
            "traducoes": {
                "espanhol": "termo equivalente em espanhol",
                "inglês": "termo equivalente em inglês",
                "português": "termo equivalente em português",
                "latim": "termo equivalente em latim"
            },
            "nota": "campo preenchido quando existem observações"
        }
        {...}
    ]
}
```

4.1.2 Estrutura JSON do `diccionari-multilinguee-de-la-covid-19.pdf`

O ficheiro `dicionario_covid.json` resulta do processamento do dicionário terminológico multilingue da COVID-19. Cada entrada corresponde a um termo em catalão, identificado por um número de entrada e acompanhado de traduções em várias línguas, podendo algumas entradas apresentarem ainda uma categoria temática e uma definição.

Todas as entradas encontram-se organizadas como pares `chave{valor`, onde a chave corresponde ao termo catalão e o valor é um objeto com a estrutura apresentada de seguida.

```
"termo_catalao": {
    "id": número identificador da entrada,
    "termo_catalao": "forma principal do termo em catalão",
    "traducoes": {
        "occitan": "equivalente em occitano",
        "euskera": "equivalente em euskera",
        "galego": "equivalente em galego",
        "espanhol": "equivalente em espanhol",
        "inglês": "equivalente em inglês",
        "francês": "equivalente em francês",
        "português (PT)": "equivalente em português europeu",
        "português (BR)": "equivalente em português do Brasil",
        "holandês": "equivalente em holandês"
    },
    "categoria": "categoria temática (quando presente, pode ser:
    'ETIOPATOGÈNIA.', 'CLÍNICA.', 'EPIDEMIOLOGIA.', 'TRACTAMENT.' e
    'PRINCIPIS ACTIUS.')",
    "definicao": "definição associada ao termo (quando presente)"
}
```

4.1.3 Estrutura JSON do `glossario_enfermagem.pdf`

O ficheiro `glossario_enfermagem.json` apresenta uma estrutura simples e direta, refletindo a organização do glossário original. Cada entrada consiste num par `chave{valor`, onde a chave corresponde ao termo e o valor contém a respetiva definição.

O glossário é constituído exclusivamente por termos e definições, não existindo categorias temáticas, sinónimos, traduções ou metadados adicionais.

A estrutura geral do ficheiro é a seguinte:

```
{
    "Termo 1": "Definição correspondente ao termo 1.",
    "Termo 2": "Definição correspondente ao termo 2.",
    "Termo 3": "Definição correspondente ao termo 3.",
    ...
}
```

Cada termo é representado como uma string e cada definição corresponde a um texto contínuo, podendo variar em extensão. Esta estrutura facilita a consulta direta, mas contrasta com a complexidade dos dicionários criados para os restantes documentos, que incluem múltiplos campos e níveis de informação.

4.1.4 Estrutura JSON do `glossario_termos_medicos.pdf`

O ficheiro `glossario_termos_medicos.json` apresenta uma estrutura simples e direta, semelhante à do glossário de enfermagem. Cada entrada consiste num par `chave{valor`, onde a chave corresponde ao termo médico e o valor contém a respetiva definição.

Tal como no glossário de enfermagem, não existem categorias temáticas, sinónimos estruturados, traduções ou metadados adicionais. No entanto, algumas definições incluem múltiplas variantes ou explicações adicionais numa única string, refletindo a heterogeneidade do documento original.

Assim, a estrutura geral do ficheiro é a seguinte:

```
{
    "Termo 1": "Definição correspondente ao termo 1.",
    "Termo 2": "Definição correspondente ao termo 2, podendo incluir
                variantes ou explicações adicionais.",
    "Termo 3": "Definição correspondente ao termo 3.",
    ...
}
```

Cada termo é representado como uma string simples, e cada definição corresponde a um texto contínuo, podendo incluir sinónimos, variantes ou descrições complementares.

4.2 Heterogeneidade estrutural dos dados

Os quatro documentos JSON processados apresentam estruturas internas muito distintas, variando na complexidade da informação, na organização dos campos e na forma como os termos são representados. Esta heterogeneidade impede a integração direta dos dados, tornando necessária uma etapa adicional de normalização e unificação da estrutura JSON.

4.3 Processo de unificação dos dados (`unificar.py`)

Para integrar os diferentes ficheiros JSON produzidos a partir dos vários documentos, foi desenvolvido o script `unificar.py` com o objetivo de normalizar campos, reorganizar informação e converter formatos distintos numa estrutura comum.

O processo consiste na leitura dos vários ficheiros JSON individuais, na extração dos elementos relevantes de cada um e na sua transformação para uma estrutura uniforme, permitindo a criação de um dicionário final consolidado. Esta etapa garante a compatibilidade entre dados provenientes dos documentos com níveis de complexidade e organização muito distintos.

4.4 Estrutura do dicionário unificado final (dicionario_unificado.json)

O ficheiro dicionario_unificado.json corresponde ao resultado da integração de todas os ficheiros processados, já convertidos para um modelo comum. Cada entrada do dicionário final mantém a estrutura base do medicina.json, enriquecida com traduções adicionais e definições provenientes dos restantes glossários, conforme demonstrado de seguida.

```
{
    "Vocabulário médico": [
        {
            "termo_galego": {
                "palavra": "forma principal do termo em galego",
                "genero_palavra": "género gramatical (quando disponível)",
                "sinonimos_galego": ["lista de sinónimos, quando existentes"]
            },
            "tema": ["lista de temas associados ao termo"],
            "traducoes": {
                "espanhol": "equivalente em espanhol",
                "inglês": "equivalente em inglês",
                "português": "equivalente(s) em português",
                "francês": "equivalente em francês",
                "holandês": "equivalente em holandês",
                ...
            },
            "definição": "definição integrada a partir dos glossários,
            quando existente"
        }
        {...}
    ]
}
```

5 Desafios encontrados e soluções

O processamento dos quatro dicionários revelou um conjunto de desafios que resultam da heterogeneidade estrutural, da variabilidade linguística e das limitações inerentes à extração automática de texto a partir de documentos PDF. Nesta secção são sintetizados os principais desafios encontrados e as estratégias adotadas para os ultrapassar.

- **Inconsistências estruturais nos documentos**

  Os documentos apresentavam diferenças significativas na forma como organizavam a informação: alguns incluíam numeração explícita, outros não; alguns separavam campos por formatação, outros misturavam termos, definições e sinónimos na mesma linha.

  Solução: foram definidas expressões regulares e regras de segmentação específicas para cada documento, adaptadas aos seus padrões internos, garantindo a extração consistente dos campos relevantes.

- **Quebras de linha e ruído textual**

  A conversão dos PDFs originou quebras de linha indesejadas, espaços redundantes, cabeçalhos repetidos e outros elementos residuais que interferiam na interpretação das entradas.

  Solução: aplicaram-se rotinas de limpeza e normalização, removendo ruído, unificando blocos de texto e garantindo que cada entrada surgia de forma contínua.

- **Variação na apresentação de sinónimos e traduções**

  Os documentos utilizavam padrões de escrita diferentes para apresentar sinónimos, variantes terminológicas e traduções noutras línguas, dificultando a extração automática.

  Solução: foram criados padrões de deteção específicos para cada tipo de marcação (por exemplo, *SIN.*-, códigos linguísticos ou formas populares), permitindo organizar estes elementos em listas estruturadas.

- **Notas extensas e campos opcionais**

  Alguns documentos incluíam notas longas, distribuídas por várias linhas, enquanto outros omitiam completamente determinados campos.

  Solução: implementou-se uma lógica flexível que permitiu identificar notas que ocupassem várias linhas e, simultaneamente, lidar com entradas incompletas sem comprometer a estrutura final.

- **Unificação de estruturas heterogéneas**

  A fusão dos quatro dicionários exigiu a definição de uma estrutura comum capaz de incorporar a informação proveniente de fontes muito distintas, com níveis de complexidade variáveis.

  Solução: foi criado um modelo JSON unificado, suficientemente abrangente para integrar campos linguísticos, temáticos e conceptuais, garantindo consistência e compatibilidade entre todas as entradas.

6 Aplicação Web

Com o objetivo de disponibilizar o dicionário unificado através de uma interface acessível, foi desenvolvida uma aplicação *web* em *Python* utilizando o *microframework* `Flask`. A camada de apresentação foi desenvolvida em HTML e o motor de templates do `Flask Jinja2`, permitindo gerar páginas de forma dinâmica e mantendo uma separação clara entre a lógica da aplicação e a interface.

6.1 Arquitetura geral

A aplicação organiza-se em dois componentes principais:

- ***Backend*** `Flask`: responsável pelo carregamento do dicionário, definição das rotas e implementação da lógica de pesquisa e navegação.
- ***Frontend*** **(HTML)**: responsável pela apresentação dos conteúdos estruturada em templates reutilizáveis.

6.2 Estrutura do ficheiro `app.py`

O ficheiro `app.py` contém toda a lógica da aplicação, distribuída por quatro blocos funcionais.

6.2.1 Carregamento do dicionário

A função `carregar_dados()` procede à leitura do ficheiro `dicionario_unificado.json`, devolvendo a lista de termos médicos. Inclui tratamento de exceções, garantindo que eventuais erros de leitura não interrompem a execução da aplicação, devolvendo uma lista vazia em caso de falha.

6.2.2 Rotas principais

A aplicação disponibiliza quatro rotas:

- `/`: página inicial.
- `/conceitos`: listagem completa dos termos médicos, ordenados alfabeticamente.

- `/conceitos/<designacao>`: página de detalhe de um termo específico.
- `/pesquisar`: página de pesquisa, permitindo procurar termos por equivalências ou traduções.

Cada rota utiliza um template distinto, recebendo os dados necessários a partir do *backend*.

6.2.3 Página de consulta do conceito

A rota `/conceitos/<designacao>` procura no dicionário o termo correspondente à designação fornecida na URL. Caso o termo não exista, é devolvida uma mensagem de erro. Quando encontrado, o objeto completo é enviado para o template `conceito.html`, que apresenta:

- termo principal e género;
- áreas temáticas;
- sinónimos;
- traduções para várias línguas;
- definição integrada (quando disponível).

6.2.4 Sistema de pesquisa

A rota `/pesquisar` permite procurar termos por:

- forma principal em galego;
- traduções existentes;
- sinónimos.

A pesquisa é feita por correspondência exata, ignorando diferenças de maiúsculas/minúsculas. Os resultados são apresentados numa lista dinâmica, onde cada entrada contém um link para a página de detalhe do termo correspondente.

6.3 Templates HTML

A camada de apresentação utiliza o motor de templates do `Flask Jinja2`, permitindo herança e reutilização de componentes.

6.3.1 Template `layout.html`

Define a estrutura base da aplicação, incluindo:

- cabeçalho HTML;
- barra de navegação;
- bloco `{% block content %}` para inserção de conteúdo específico.

Todos os restantes templates estendem este ficheiro.

6.3.2 Template `home.html`

Apresenta a página inicial, contendo:

- título da aplicação;
- breve descrição;
- botão de acesso à listagem de conceitos.

6.3.3 Template `conceitos.html`

Responsável pela listagem alfabética dos termos médicos. Gera dinamicamente uma grelha de links, cada um apontando para a página de consulta do respetivo termo.

6.3.4 Template `conceito.html`

Apresenta a informação detalhada de um termo, organizada em cartões e tabelas para facilitar a leitura.

6.3.5 Template `pesquisar.html`

Implementa o formulário de pesquisa e apresenta os resultados correspondentes, incluindo:

- termo encontrado;
- género;
- áreas temáticas;
- link para a página de detalhe.

7 Conclusão

O trabalho desenvolvido permitiu aplicar, de forma prática, vários conceitos fundamentais de Processamento de Linguagem Natural, desde a análise de documentos não estruturados até à construção de representações formais em JSON. A diversidade dos quatro glossários analisados exigiu abordagens de extração distintas, adaptadas às características de cada documento, bem como etapas de limpeza e normalização para garantir consistência entre as entradas.

A definição de uma estrutura comum tornou possível unificar todos os recursos num único dicionário consolidado, reunindo informação terminológica, temática, multilingue e conceptual. Este dicionário final constitui um recurso organizado e extensível, adequado para consulta no futuro.

Como etapa final, foi desenvolvida uma aplicação *web* em `Flask` que disponibiliza o dicionário através de uma interface simples e intuitiva, permitindo pesquisar termos e consultar traduções e notas associadas. Esta componente demonstra como o processamento automático pode ser integrado numa solução prática e acessível ao utilizador.

Referências

[1] C. D. Manning. Human language understanding & reasoning, 2022. Acessado em abril de 2026.