

Trabalho Prático 2

MESTRADO EM ENGENHARIA BIOMÉDICA

2025/2026

PROCESSAMENTO DE LINGUAGEM NATURAL

Ana Beatriz Zeferino (PG59852)

Daniela Coelho (PG59872)

Daniela Rodrigues (PG59757)



Indice

01 Contexto

02 Objetivos

03 Enriquecimento do
Dataset

04 Plataforma Web

05 Sistema de
Information Retrieval

06 Sistema de
Question Answering

07 Conclusão



Introdução

Problema

Informação médica abundante, mas frequentemente não estruturada.


Objetivo

Enriquecimento do glossário médico desenvolvido e desenvolvimento de mecanismo de exploração e pesquisa.

Solução


- Enriquecimento do conjuntos de dados;
- Plataforma Web para gestão e consulta;
- Sistema de *Information Retrieval*;
- *Sistema de Question Answering*;

Enriquecimento do Dataset




Atlas da Saúde

Glossário de doenças em português e respectivas definições




Dicionário Médico

Glossário de termos médicos em português e respectivas definições



Dicionário Galego

Glossário de termos médicos em galego e respectivas definições



Medical Dictionary

Glossário de termos médicos em língua inglesa e respectivas definições

Lógica de Integração

doencastodas.json

As definições são integradas nos termos correspondentes através do mapeamento entre o português e o galego;

medical_dictionary.json

As definições em inglês são adicionadas apenas às entrada cujo termo traduzido em inglês corresponde;

dicionario_galego_medico.json

Caso o termo já exista na base de dados, este é enriquecido com informação adicional, caso contrário, é criada uma nova entrada;

dicionario_site.json

As definições em português são integradas nos termos correspondentes;

Plataforma Web



Plataforma Web



Módulo Vocabulário

- Pesquisa de termos por texto livre ou área temática;
- Adição e edição de termos;



Módulo *Information Retrieval*

- Pesquisa de artigos científicos por consulta formulada em Linguagem Natural;
- Dois métodos: TD-IDF e SBERT;



Módulo *Question Answering*

- Permite ao utilizador formular questões em linguagem natural com base no resumo de um artigo selecionado;

Sistema de *Information Retrieval*

Modelo TF-IDF

Pré-processamento

- Modelo pt_core_news_sm (spacY)
- Remoção de stopwords
- Filtragem não-alfabética
- Conversão para minúsculas

TF (term freq.)

- Frequência relativa de cada termo no documento

$$TF(t, d) = \frac{\text{nº de ocorrências de } t \text{ em } d}{\text{total de termos em } d}$$

IDF (Inverse Doc Freq.)

- Raridade do termo na coleção

$$IDF(t) = \log_{10} \left(\frac{N}{df(t)} \right)$$

N = total de documentos

Similaridade

- Produto interno entre vetores TF-IDF da query e de cada documento
- + Bónus título (+0.15)
- + Bónus keywords (+0.10)

Sistema de *Information Retrieval*

Modelo TF-IDF

Embeddings

Conversão do texto e query em vetores através do modelo

lfcc/medlink-bi-encoder

Pesquisa semântica

Cálculo da proximidade da query aos documentos através da similaridade do cosseno

Ordenação e resultados

Seleção dos artigos com maior proximidade e apresentação dos resultados

Comparação entre abordagens

Critério	TF-IDF	SBERT
Tipo de representação	Frequência de termos	<i>Embeddings</i> semânticos
Sensível a sinónimos	Não	Sim
Dependência do vocabulário	Elevada	Baixa
Pré-processamento da <i>query</i>	Sim (explícito)	Não (interno ao modelo)
Campos indexados	Resumo	Título + <i>keywords</i> + resumo
Bónus de relevância	Título e <i>keywords</i>	Não (implícito no texto)
Índice pré-calculado	Sim (ficheiro JSON)	Não (gerado no arranque)
Medida de similaridade	Cosseno + bónus	Cosseno
Custo computacional	Baixo	Médio
Top- <i>k</i> devolvido	10 (<i>score</i> > 0)	10
Adequado para textos biomédicos	Moderado	Elevado

Sistema de *Question Answering*

Modelo BERT utilizado **pierreguillou/bert-base-cased-squad-v1.1-portuguese**, baseado em BERTimbau e afinado para a tarefa de Question Answering usando o dataset SQuAD v1.1.

Utilizador **formula**
questões em
linguagem natural
sobre um artigo
selecionado;

Resumo do
artigo é usado
como contexto e
respostas são
geradas pelo
modelo;

O sistema **devolve**
a resposta
extraída,
acompanhada da
respetiva
pontuação de
confiança.

Conclusão

- Desenvolvimento de uma **plataforma Web** completa para **exploração de um vocabulário médico multilingue** e de um conjunto de artigos científicos, integrando funcionalidades de pesquisa e *Question Answering*;
- O módulo de **Information Retrieval** combina duas abordagens complementares: **TF-IDF**, reforçado com bónus de relevância para título e palavras-chave, e **SBERT**, que utiliza representações semânticas enriquecidas;
- O módulo de **Question Answering**, baseado num modelo pré-treinado, permite obter respostas diretas fundamentadas no conteúdo dos artigos recuperados.

Trabalho Prático 2

MESTRADO EM ENGENHARIA BIOMÉDICA

2025/2026

PROCESSAMENTO DE LINGUAGEM NATURAL

Ana Beatriz Zeferino (PG59852)

Daniela Coelho (PG59872)

Daniela Rodrigues (PG59757)

