

Universidade do Minho

Processamento de Linguagem Natural

Trabalho Prático 2

Grupo 3

Ana Beatriz Zeferino (pg59852)

Daniela Coelho (pg59872)

Daniela Rodrigues (pg59757)

Braga, junho de 2026



Resumo

O presente relatório descreve o desenvolvimento de uma plataforma *Web* destinada à exploração do conjunto de dados `dicionario_unificado.json`, elaborado no âmbito do Trabalho Prático 1 da unidade curricular de Processamento de Linguagem Natural. A plataforma desenvolvida permite a visualização e manipulação dos dados, integrando um sistema de *Information Retrieval* (IR), bem como um módulo de *Question Answering* (QA) baseado em modelos de linguagem pré-treinados. A execução deste trabalho foi organizada em quatro fases distintas: enriquecimento do conjunto de dados, construção da plataforma *Web*, implementação do sistema de IR e integração do modelo de QA.



Índice

1	Introdução	1
2	Enriquecimento do <i>Dataset</i>	1
2.1	<i>Datasets</i> Adicionais	2
2.1.1	Glossário <i>Atlas da Saúde</i>	3
2.1.2	Glossário <i>Medical Dictionary of Health - Harvard Health Publishing</i>	3
2.1.3	Glossário <i>Dicionário Médico</i>	3
2.1.4	Glossário <i>DICCIONARIOGALEGOmedico.xml</i>	3
2.2	Concatenação dos <i>datasets</i>	4
2.2.1	Estrutura dos Dados	4
2.2.2	Lógica de integração	5
3	Plataforma Web	6
3.1	Funcionalidades	7
3.1.1	Módulo Vocabulário	7
3.1.2	Módulo de <i>Information Retrieval</i>	8
3.1.3	Módulo de <i>Question Answering</i>	8
4	Sistema de <i>Information Retrieval</i>	9
4.1	Pré-processamento dos documentos	10
4.2	Modelo baseado em TF-IDF	10
4.2.1	Cálculo de TF	10
4.2.2	Cálculo de IDF	10
4.2.3	Vetores TF-IDF	11
4.2.4	Medida de Similaridade	11
4.3	Modelo baseado em SBERT	11
4.3.1	Modelo utilizado	12
4.3.2	Construção do índice com texto enriquecido	12
4.3.3	Pesquisa	13
4.4	Integração na aplicação Web	13



4.5	Comparação entre abordagens	13
5	Sistema de <i>Question Answering</i>	14
6	Desafios encontrados e soluções	15
7	Conclusão	16



Lista de Figuras

1	Página inicial da Plataforma <i>Web</i>	7
2	Página inicial do módulo de vocabulário	7
3	Página disponibilizada para a adição de novos termos	8
4	Página disponibilizada pelo módulo <i>Information Retrieval</i>	8
5	Página disponibilizada pelo módulo <i>Question Answering</i>	9



1 Introdução

A crescente digitalização da informação clínica e biomédica tem originado grandes volumes de documentos em formato não estruturado, como PDFs de glossários, artigos científicos e registos médicos. Extrair e organizar automaticamente este conteúdo tornou-se, por isso, um desafio relevante no contexto do Processamento de Linguagem Natural (PLN) aplicado à Engenharia Biomédica.

No Trabalho Prático 1 foi desenvolvido um sistema capaz de processar documentos PDF do domínio médico e convertê-los para um formato estruturado. O resultado foi o ficheiro `glossario.termos.medicos.json`, que contém definições, traduções, sinónimos e outras informações associadas a termos médicos.

Partindo deste conjunto de dados, o presente trabalho iniciou-se com o seu enriquecimento através da integração de várias fontes externas, incluindo glossários em português, inglês e galego. Esta etapa permitiu ampliar e complementar o vocabulário inicial.

De seguida, foi desenvolvida uma plataforma *Web* para explorar o *dataset* enriquecido, oferecendo funcionalidades de pesquisa, filtragem, ordenação e edição dos conceitos.

Em paralelo, foi implementado um sistema de *Information Retrieval* (IR) para pesquisar artigos científicos da área médica, recorrendo a duas abordagens: um modelo clássico baseado em TF-IDF e um modelo semântico baseado em *Sentence-BERT* (*SBERT*).

Por fim, integrou-se um módulo de *Question Answering* (QA) que permite ao utilizador colocar questões em linguagem natural sobre um artigo recuperado pelo sistema de IR, obtendo respostas automáticas fundamentadas no seu conteúdo.

2 Enriquecimento do *Dataset*

Inicialmente, e antes de dar início à fase de enriquecimento do conjunto de dados, foi necessário corrigir algumas falhas existentes no `dataset.dicionario.unificado.json`, desenvolvido no trabalho anterior.

Entre as principais otimizações realizadas, destacam-se:



1. A identificação das línguas foi normalizada através da utilização dos respetivos códigos ISO, de acordo com o seguinte mapeamento.

```
MAP_LINGUA = {  
    "espanhol":      "es",  
    "inglês":        "en",  
    "português":     "pt",  
    "latim":         "la",  
    "francês":       "fr",  
    "euskera":       "eu",  
    "holandês":      "nl",  
    "occitan":       "oc",  
    "português (BR)": "pt_BR",  
    "português (PT)": "pt_PT",  
}
```

2. Construção de um vocabulário com chaves mais curtas;
3. Remoção de campos vazios ou inconsistentes.

Estas melhorias foram essenciais para a condensação e organização do código, bem como para garantir uma estrutura de dados mais consistente e eficiente.

2.1 *Datasets* Adicionais

De modo a cumprir o objetivo de enriquecimento do conjunto de dados, foram utilizados como fonte diferentes recursos para a extração de informação. Uma vez que a maioria da informação presente nos conjuntos de dados armazenados em formato JSON foi obtida a partir da *Web*, utilizaram-se bibliotecas de *Web scraping*, como a *BeautifulSoup*, para a sua extração e tratamento.

Os conjuntos de dados adicionais utilizados são descritos nas subsubsecções seguintes.



2.1.1 Glossário *Atlas da Saúde*

O *Atlas da Saúde* é um portal de informação em saúde que reúne conteúdos sobre diversas áreas médicas, incluindo uma secção específica de doenças organizada segundo a ordem alfabética. Foi possível recolher informação relativa a diversas doenças, incluindo as respetivas definições, que foram posteriormente estruturadas e integradas na base de dados terminológica.

2.1.2 Glossário *Medical Dictionary of Health - Harvard Health Publishing*

À semelhança do recurso anterior, o *Medical Dictionary of Health*, disponibilizado pela *Harvard Health Publishing*, trata-se de um glossário de consulta online, com termos médicos organizados por ordem alfabética e acompanhados das respetivas definições. A principal particularidade deste glossário é o facto de estar em língua inglesa, o que permitiu o enriquecimento do conjunto de dados através da pesquisa de termos em inglês no glossário de termos médicos, adicionando-se as respetivas descrições em inglês aos termos compatíveis nos dois *datasets*.

2.1.3 Glossário *Dicionário Médico*

A informação utilizada na construção do glossário *Dicionário Médico* foi extraída de uma página *Web* especializada em terminologia médica, que disponibiliza um vasto conjunto de termos em português, acompanhados das respetivas definições. A utilização desta fonte permitiu aumentar significativamente a quantidade e a qualidade da informação presente no ficheiro JSON final, uma vez que muitos dos termos inicialmente recolhidos não possuíam qualquer definição associada. Assim, foi possível complementar esses registos com descrições adequadas, tornando o glossário mais completo, informativo e útil para os utilizadores.

2.1.4 Glossário `DICCIONARIOGALEGOmedico.xml`

Embora o vocabulário de base do sistema seja constituído por termos em língua galega, a integração do ficheiro `DICCIONARIOGALEGOmedico.xml` teve como objetivo complementar e enriquecer os recursos terminológicos já existentes. Este recurso



fornece informação adicional sobre conceitos da área médica, permitindo aumentar a cobertura lexical do sistema e incorporar novas designações, definições e relações terminológicas.

2.2 Concatenação dos *datasets*

A concatenação dos diversos ficheiros resultantes da extração de informação da *Web* foi realizada pelo *script* `juncao_final.py`, cuja principal função consiste em consolidar e unificar os múltiplos dicionários médicos num único glossário terminológico em formato JSON. Para tal, o *script* efetua a leitura de vários ficheiros de entrada e integra a informação contida em cada um deles numa base de dados principal em formato JSON.

Os ficheiros utilizados como entrada pelo *script* `juncao_final.py` são os seguintes:

- `dicionario_unificado.json`: ficheiro correspondente ao resultado final do Trabalho Prático 1;
- `dicionario_galego_medico.json`: ficheiro gerado a partir da extração de informação do glossário `DICCIONARIOGALEGOmedico.xml`;
- `doencastodas.json`: ficheiro produzido a partir da recolha de informação do portal *Altas da Saúde*.
- `dicionario_site.json`: ficheiro gerado a partir da recolha de definições e terminologia médica do *Dicionário Médico*;
- `medical_dictionary.json`: ficheiro resultante da extração de termos e definições provenientes do *Medical Dictionary of Health*.

2.2.1 Estrutura dos Dados

As entradas do vocabulário seguem uma estrutura uniforme, constituída pelos seguintes campos:



Tabela 1: Estrutura dos campos do vocabulário terminológico

Campo	Descrição
tg	Termo principal em galego, que pode incluir informação adicional, como sinónimos (sin) e género gramatical (gen).
trad	Conjunto de traduções do termo para outras línguas, como português, inglês, espanhol e latim.
def	Definição do termo. Definições provenientes de diferentes fontes são concatenadas e separadas pelo símbolo .
relacionados	Lista de termos semanticamente relacionados.
tema	Área temática ou domínio médico ao qual o termo pertence.

A estrutura seguinte representa a organização dos dados associada a cada termo presente no vocabulário.

```
{
  "tg": {
    "pal": "",
    "gen": ""
  },
  "tema": [],
  "trad": {
    "es": "",
    "en": "",
    "pt": "",
    "la": ""
  },
  "def": ""
}
```

2.2.2 Lógica de integração

O processo de junção dos diferentes conjuntos de dados segue uma estratégia de correspondência baseada na normalização textual, que consiste na remoção de



acentos e na conversão de todos os termos para minúsculas. Este procedimento permite reduzir inconsistências e evitar a criação de entradas duplicadas.

A integração das diferentes fontes é realizada de acordo com regras específicas para cada conjunto de dados:

- `DICCIONARIOGALEGOmedico.xml`: caso o termo já exista na base de dados, este é enriquecido com informação adicional, como definições, sinónimos e termos relacionados; caso contrário, é criada uma nova entrada;
- `doencastodas.json`: as definições são integradas nos termos correspondentes através do mapeamento entre o português e o galego;
- `medical_dictionary.json`: as definições em inglês são adicionadas apenas às entradas que já possuam uma tradução em inglês reconhecida;
- `dicionario_site.json`: as definições em português são integradas de forma semelhante ao processo aplicado ao ficheiro `doencastodas.json`.

O ficheiro de saída `dicionario_final.json` contém o vocabulário consolidado sob a chave "vocab", sendo o número total de termos apresentado no final da execução do *script*.

3 Plataforma Web

A aplicação *Web* foi desenvolvida em *Python*, com recurso ao *framework Flask*, constituindo o principal ponto de interface de acesso ao sistema terminológico e ao *corpus* de artigos científicos. A arquitetura desenvolvida encontra-se organizada em três módulos funcionais principais: o dicionário terminológico, o motor de recuperação de informação e o sistema de resposta a perguntas.

A Figura 1 apresenta a página inicial da plataforma desenvolvida, bem como os módulos que a constituem no respetivo cabeçalho.



Figura 1: Página inicial da Plataforma Web

3.1 Funcionalidades

3.1.1 Módulo Vocabulário

O módulo de vocabulário disponibiliza o vocabulário galego-médico previamente consolidado, permitindo a pesquisa de termos através de texto livre ou por área temática, com apresentação dos resultados ordenados alfabeticamente (ignorando caracteres iniciais como - e *).

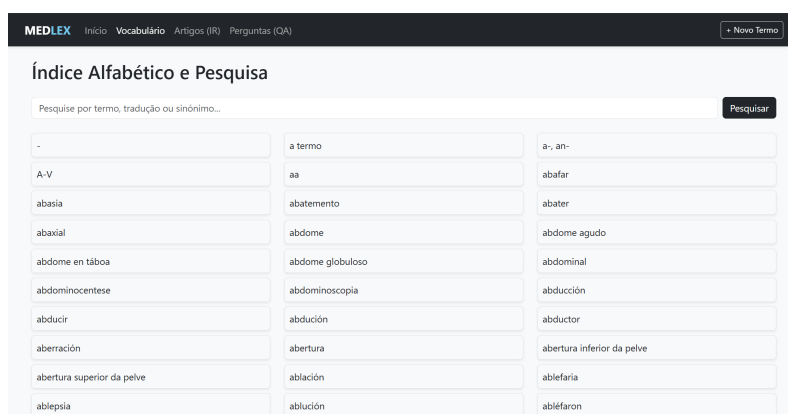


Figura 2: Página inicial do módulo de vocabulário

Cada entrada inclui o termo em galego, bem como as respetivas traduções em várias línguas (português, inglês, espanhol, latim, francês, occitano, basco e holandês), para além da definição, sinónimos e termos relacionados. A pesquisa abrange simultaneamente o termo galego, as traduções e os sinónimos.

Além da pesquisa e consulta de termos, a aplicação permite ainda a adição de novos termos e a atualização de conteúdos diretamente na interface, conforme ilustrado na figura abaixo.



The screenshot shows the 'Novo Conceito Clínico' form. It has a header with 'MEDLEX' and navigation links: 'Início', 'Vocabulário', 'Artigos (IR)', 'Perguntas (QA)', and a '+ Novo Termo' button. The form sections are: 'Termo (Galego) *' with a text input containing 'Ex: miocardio'; 'Género Gramatical' with a dropdown showing 'm, f, mf'; 'Sinónimos' with a text input 'Separados por vírgula'; 'Áreas Temáticas' with a text input 'Ex: Anatomia'; 'Definição / Nota Clínica' with a large text area 'Insira a descrição médica do termo...'; and 'TRADUÇÕES CORRESPONDENTES' with three text inputs for 'Português', 'Espanhol', and 'Inglês'. At the bottom are 'Adicionar Termo' and 'Voltar' buttons.

Figura 3: Página disponibilizada para a adição de novos termos

3.1.2 Módulo de *Information Retrieval*

O motor de recuperação de informação opera sobre o *corpus* de artigos científicos e disponibiliza dois métodos complementares de pesquisa: TF-IDF e SBERT.

O utilizador introduz uma *query* em linguagem natural e seleciona o método pretendido, sendo-lhe apresentados os artigos ordenados por relevância. Pode, em seguida, aceder ao artigo selecionado para posterior utilização no módulo de QA.

The screenshot shows the 'Recuperação de Informação' page. It has a header with 'MEDLEX' and navigation links: 'Início', 'Vocabulário', 'Artigos (IR)', 'Perguntas (QA)', and a '+ Novo Termo' button. The page title is 'Recuperação de Informação' with a subtitle 'Efetue pesquisas textuais ou semânticas na base de dados de artigos biomédicos carregados.' Below is a search bar 'Introduza termos, frases clínicas ou conceitos semânticos...' with a 'Pesquisar' button. A 'MÉTODO DE BUSCA' dropdown is set to 'TF-IDF (Palavras-chave exatas)' with an option for 'Sentence-BERT (Similaridade Semântica / IA)'. Below is a section 'Artigos Clínicos na Coleção (812)' with a grid of four article cards. Each card has a title, authors, and a 'Ver Artigo' button.

Artigo 1	Artigo 2
VASCULITE SECUNDÁRIA A INFECÇÃO PULMONAR POR ENTAMOEBA HISTOLYTICA C. Pais, A. R. Lima, A. Morais	PROTEINOSE ALVEOLAR PULMONAR: DIAGNÓSTICO DIFERENCIAL DAS ALTERAÇÕES DA TELERRADIOGRAFIA TORÁCICA. Cátia Canelas, Juliana Pinho, João Carvas, Joana Lemos, Ana Campos.
UM CASO DE INTOXICAÇÃO AGUDA POR COCAÍNA Margarida Eulálio ¹ , Arsénio Santos ² , Augusta Cipriano ³ , Rui Santos ⁴ , Armando Carvalho ⁵	PENFIGOIDE BOLHOSO INDUZIDO POR INIBIDOR DA DIPEPTIDIL PEPTIDASE 4: IMAGEM DE UM CASO CLÍNICO Mylene Costa (0000-0002-5132-0632), Francisco Simões de Carvalho (0000-0002-0669-2550), Herberto Bettencourt (0000-0002-7395-0475), Marta Pereira (0000-0003-0280-1314)

Figura 4: Página disponibilizada pelo módulo *Information Retrieval*

3.1.3 Módulo de *Question Answering*

O módulo de *question answering* permite ao utilizador formular questões em linguagem natural com base no resumo de um artigo selecionado.

As respostas são geradas pelo modelo `pierreguillou/bert-base-cased-squad-v1.1-portuguese`, uma variante do BERTimbau ajustada para *extractive question answering* em



língua portuguesa. O sistema devolve a resposta extraída, acompanhada da respetiva pontuação de confiança.

Os modelos de linguagem utilizados, nomeadamente o SBERT e o modelo de QA, são inicializados apenas uma vez durante o arranque do servidor e mantidos em memória ao longo de toda a execução da aplicação, garantindo tempos de resposta reduzidos nas interações subsequentes.



Figura 5: Página disponibilizada pelo módulo *Question Answering*

4 Sistema de *Information Retrieval*

O sistema de *Information Retrieval* (IR) desenvolvido neste trabalho tem como objetivo permitir a pesquisa eficiente de artigos científicos da área médica, retornando os documentos mais relevantes para uma consulta formulada em linguagem natural. Para cumprir os requisitos do enunciado, foram implementadas duas abordagens complementares: um modelo clássico baseado em TF-IDF e um modelo semântico baseado em SBERT. Ambas as metodologias foram integradas na aplicação *Web*, permitindo ao utilizador seleccionar o método de pesquisa pretendido.

A lógica de cada abordagem encontra-se nos módulos `ficheiros/tf_idf.py` e `ficheiros/sbert.py`, sendo invocada pelo `app.py` através das respetivas funções de pesquisa.



4.1 Pré-processamento dos documentos

Antes da indexação, o conteúdo textual de cada artigo é submetido a um processo de normalização linguística. Este pré-processamento é realizado com recurso à biblioteca `spaCy`, utilizando o modelo `pt_core_news_sm`, e inclui:

- remoção de *stopwords*;
- filtragem de tokens não alfabéticos e de pontuação;
- conversão para minúsculas;
- tokenização.

Este procedimento é aplicado tanto ao *corpus* de documentos durante a fase de indexação (via `script auxiliares/gerar_tfidf.py`), como à *query* introduzida pelo utilizador, através da função `pre_processar_query()` definida em `tf_idf.py`, garantindo consistência entre as representações comparadas.

4.2 Modelo baseado em TF-IDF

A primeira abordagem implementada segue o modelo clássico de recuperação de informação, no qual cada documento é representado como um vetor de pesos TF-IDF. A sua implementação encontra-se no módulo `ficheiros/tf_idf.py` e inclui as etapas a seguir descritas.

4.2.1 Cálculo de TF

Para cada documento, é calculada a frequência relativa de cada termo:

$$TF(t, d) = \frac{\text{n}^{\text{o}} \text{ de ocorrências de } t \text{ em } d}{\text{total de termos em } d}$$

4.2.2 Cálculo de IDF

A raridade de cada termo na coleção é obtida através de:

$$IDF(t) = \log_{10} \left(\frac{N}{df(t)} \right)$$

onde N é o número total de documentos e $df(t)$ o número de documentos que contêm o termo t .



4.2.3 Vetores TF-IDF

O peso final de cada termo resulta do produto:

$$TFIDF(t, d) = TF(t, d) \times IDF(t)$$

Os vetores dos documentos são construídos e alinhados com um vocabulário global (`termos_globais`) partilhado por toda a coleção, condição necessária para o correto cálculo da similaridade do cosseno. Para otimização de desempenho, a matriz TF-IDF é pré-calculada pelo *script* `auxiliares/gerar_tfidf.py` e armazenada em `jsons/tfidf_artigos.json`. A função `carregar_indice()` do módulo `tf_idf.py` carrega esta matriz em memória no arranque da aplicação, evitando recomputação.

4.2.4 Medida de Similaridade

A relevância base entre a *query* e cada documento é calculada através da similaridade do cosseno:

$$\cos(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \times \|\mathbf{d}\|}$$

onde $\mathbf{q}$ e $\mathbf{d}$ são os vetores TF-IDF da *query* e do documento, respetivamente. Os documentos são ordenados por este valor, sendo devolvidos os mais relevantes.

Para melhorar a qualidade dos resultados, o *score* base é complementado com bónus por correspondência nos campos mais informativos do artigo:

- **Bónus de título** (+0,15 por token da *query* encontrado no título do artigo);
- **Bónus de *keywords*** (+0,10 por token da *query* encontrado nas palavras-chave do artigo).

O *score* final é calculado como:

$$score_final = \min(\cos(\mathbf{q}, \mathbf{d}) + \text{bónus_título} + \text{bónus_keywords}, 1.0)$$

Após a aplicação dos bónus, os resultados são reordenados pelo *score* final, sendo devolvidos os **10 documentos** com pontuação superior a zero.

4.3 Modelo baseado em SBERT

Para complementar a abordagem clássica, foi implementado um modelo semântico utilizando *Sentence-BERT* (*SBERT*), através da biblioteca *Sentence-*



Transformers. Este modelo permite capturar relações semânticas entre palavras e frases, superando as limitações do TF-IDF, que depende apenas de correspondência lexical.

4.3.1 Modelo utilizado

Foi utilizado o modelo biomédico `lfcc/medlink-bi-encoder`, o mesmo que foi usado nas aulas, treinado especificamente para textos da área da saúde, o que melhora a qualidade das representações vetoriais dos resumos.

Foi utilizado o modelo biomédico `lfcc/medlink-bi-encoder`, treinado especificamente para textos da área da saúde. Para além de ter sido um modelo utilizado durante as aulas, a escolha de um modelo especializado no domínio biomédico, em detrimento de um modelo genérico de língua portuguesa, justifica-se pela natureza técnica do *corpus* de artigos científicos, melhorando a qualidade semântica das representações vetoriais obtidas.

4.3.2 Construção do índice com texto enriquecido

O carregamento do modelo e a geração dos *embeddings* são realizados em duas etapas distintas, definidas em `ficheiros/sbert.py`:

1. função `carregar_modelo()`: instancia o modelo `SentenceTransformer`;
2. função `construir_indice(model, artigos)`: constrói um texto enriquecido por artigo e codifica-o num *embedding* de dimensão fixa.

Em vez de codificar apenas o resumo, o índice é construído a partir de uma representação enriquecida que combina o título (repetido duas vezes para aumentar o seu peso semântico), as palavras-chave e o resumo:

$$texto_i = \text{título}_i \parallel \text{título}_i \parallel \text{keywords}_i \parallel \text{resumo}_i$$

$$\mathbf{d}_i = \text{SBERT}(texto_i)$$

Esta estratégia permite que campos mais informativos como o título e as palavras-chave tenham maior influência na representação semântica final do documento. Os vetores resultantes são armazenados em memória como tensores *PyTorch*.



4.3.3 Pesquisa

A *query* do utilizador é codificada pelo mesmo modelo:

$$\mathbf{q} = \text{SBERT}(\text{query})$$

A relevância entre a *query* e cada documento é calculada através da similaridade do cosseno, usando `util.cos_sim()` da biblioteca `SentenceTransformers`:

$$\cos(\mathbf{q}, \mathbf{d}_i) = \frac{\mathbf{q} \cdot \mathbf{d}_i}{\|\mathbf{q}\| \times \|\mathbf{d}_i\|}$$

São devolvidos os Top-10 documentos com maior pontuação de similaridade, ordenados de forma decrescente.

4.4 Integração na aplicação Web

A função `information_retrieval()` do `app.py` coordena o processo de pesquisa, delegando a lógica para os módulos especializados:

- `tfidf.search()`: quando o parâmetro de URL `method=tfidf` está ativo (valor por omissão);
- `sbert.search()`: quando o parâmetro `method=bert` está ativo

Esta separação de responsabilidades entre o `app.py` e os módulos `tfidf.py` e `sbert.py` garante uma arquitetura modular e facilmente extensível.

Com isto, a aplicação *Web* disponibiliza uma interface que permite ao utilizador:

- introduzir uma *query*;
- seleccionar o método de pesquisa (TF-IDF ou SBERT);
- visualizar os artigos ordenados por relevância;
- aceder ao artigo seleccionado para posterior utilização no módulo de *Question Answering*.

4.5 Comparação entre abordagens

A integração dos dois métodos permite comparar abordagens clássicas e modernas de IR, evidenciando as vantagens dos modelos semânticos em domínios especializados como o biomédico.



Tabela 2: Comparação entre as abordagens de IR implementadas

Critério	TF-IDF	SBERT
Tipo de representação	Frequência de termos	<i>Embeddings</i> semânticos
Sensível a sinónimos	Não	Sim
Dependência do vocabulário	Elevada	Baixa
Pré-processamento da <i>query</i>	Sim (explícito)	Não (interno ao modelo)
Campos indexados	Resumo	Título + <i>keywords</i> + resumo
Bónus de relevância	Título e <i>keywords</i>	Não (implícito no texto)
Índice pré-calculado	Sim (ficheiro JSON)	Não (gerado no arranque)
Medida de similaridade	Cosseno + bónus	Cosseno
Custo computacional	Baixo	Médio
Top- <i>k</i> devolvido	10 (<i>score</i> > 0)	10
Adequado para textos biomédicos	Moderado	Elevado

Ambas as abordagens utilizam a similaridade do cosseno como métrica de relevância base, diferenciando fundamentalmente no tipo de representação e na estratégia de ponderação dos campos do artigo. O TF-IDF aplica bónus explícitos por correspondência no título e nas palavras-chave após o cálculo da similaridade, enquanto o SBERT incorpora esses campos diretamente na representação vetorial do documento durante a fase de indexação, repetindo o título para amplificar o seu peso semântico. O SBERT é ainda capaz de identificar documentos relevantes mesmo quando a *query* utiliza sinónimos ou expressões não presentes literalmente nos documentos, o que é uma vantagem particularmente relevante no domínio biomédico, onde a variação terminológica é frequente.

5 Sistema de *Question Answering*

O módulo de resposta a perguntas recorre ao modelo `pierreguillou/bert-base-cased-squad-v1.1-portuguese`, uma variante do BERTimbau afinada (*fine-tuned*) para a tarefa de *extractive question answering* em língua portuguesa, com base no *dataset* SQuAD v1.1.

Esta abordagem não gera respostas de forma livre, mas baseia-se na extração de



um excerto diretamente do texto de contexto fornecido, correspondendo ao segmento mais relevante para a questão colocada pelo utilizador. No sistema desenvolvido, o contexto utilizado corresponde ao resumo do artigo científico previamente selecionado no módulo de recuperação de informação.

A implementação é realizada através da biblioteca `transformers` da *Hugging Face*, recorrendo à classe `pipeline`, que encapsula tanto o modelo como o respetivo *tokenizer*.

A configuração da *pipeline* é definida da seguinte forma:

```
qa_model_name = "pierreaguillou/bert-base-cased-squad-v1.1-portuguese"
qa_pipeline = pipeline(
    task="question-answering",
    model=AutoModelForQuestionAnswering.from_pretrained(qa_model_name),
    tokenizer=AutoTokenizer.from_pretrained(qa_model_name)
)
```

Dado que o carregamento dos pesos do modelo é uma operação computacionalmente intensiva, esta inicialização é efetuada apenas uma vez, durante o arranque do servidor. O modelo permanece em memória ao longo da execução da aplicação, permitindo reduzir significativamente o tempo de resposta nas interações subsequentes.

O sistema devolve, para cada pergunta, a resposta extraída do texto, acompanhada de uma pontuação de confiança (*score*) e da posição correspondente no contexto original (campos `start` e `end`).

6 Desafios encontrados e soluções

Durante o desenvolvimento do sistema foram identificados vários desafios técnicos, principalmente relacionados com a integração de dados heterogêneos, desempenho dos módulos de *Information Retrieval* e coerência entre componentes. As soluções implementadas permitiram melhorar a robustez, eficiência e consistência da aplicação.



Heterogeneidade dos dados

Os glossários utilizados apresentavam estruturas e convenções distintas, incluindo nomes de línguas não normalizados, campos em falta e definições duplicadas. Para garantir consistência, foi aplicada uma normalização textual (remoção de acentos, minúsculas e uniformização de escrita), permitindo identificar entradas equivalentes e fundir informação proveniente de diferentes fontes.

Desempenho da indexação TF-IDF

O cálculo da matriz TF-IDF no arranque da aplicação tornava o processo lento. Para resolver este problema, a matriz passou a ser pré-calculada num *script* auxiliar e guardada em ficheiro JSON. No arranque, a aplicação apenas carrega esta cache, reduzindo o tempo de inicialização para valores praticamente instantâneos.

Qualidade dos resultados de IR

O modelo TF-IDF tratava todos os campos do artigo de forma idêntica, o que levava a resultados menos relevantes. Para melhorar a ordenação, foram atribuídos bónus de relevância quando os termos da *query* surgiam no título ou nas palavras-chave. No caso do SBERT, a representação do documento foi enriquecida com título (repetido para aumentar peso semântico), palavras-chave e resumo, melhorando a recuperação de tópicos principais.

Tempo de carregamento dos modelos

Os modelos SBERT e de *Question Answering* possuem tempos de carregamento elevados. Para evitar atrasos durante a utilização, ambos são inicializados apenas uma vez no arranque do servidor Flask e mantidos em memória ao longo da execução.

7 Conclusão

O trabalho desenvolvido resultou numa plataforma *Web* completa para exploração de um vocabulário médico multilingue e de um conjunto de artigos ci-



entíficos, integrando funcionalidades de pesquisa e *Question Answering*. O enriquecimento do *dataset* permitiu construir um vocabulário mais abrangente, reunindo definições, traduções e sinónimos provenientes de várias fontes especializadas.

A aplicação *Web*, desenvolvida em *Flask*, oferece uma interface intuitiva que permite pesquisar conceitos, recuperar artigos relevantes e colocar questões em linguagem natural sobre os documentos selecionados.

O módulo de *Information Retrieval* combina duas abordagens complementares: TF-IDF, reforçado com bónus de relevância para título e palavras-chave, e SBERT, que utiliza representações semânticas enriquecidas. Esta combinação permite ao utilizador escolher entre uma pesquisa mais literal ou uma pesquisa semântica mais robusta.

Por fim, o módulo de *Question Answering*, baseado num modelo pré-treinado, permite obter respostas diretas fundamentadas no conteúdo dos artigos recuperados, completando o ciclo de exploração da informação biomédica.

Em conjunto, estes componentes demonstram como técnicas de Processamento de Linguagem Natural, desde modelos clássicos até *transformers*, podem ser integradas para construir sistemas eficazes de acesso e análise de conhecimento na área da saúde.



Uso de ferramentas de Inteligência Artificial

Ao longo do desenvolvimento deste trabalho foram utilizadas ferramentas de Inteligência Artificial com o objetivo de apoiar o processo de implementação e produção do relatório. O recurso a estas ferramentas teve um papel exclusivamente auxiliar, não substituindo a análise crítica, as decisões técnicas ou o trabalho de programação realizado pelo grupo.

No desenvolvimento do código, a IA foi utilizada sobretudo para esclarecer dúvidas pontuais, sugerir melhorias de organização e auxiliar na identificação de erros. Todas as funcionalidades implementadas, incluindo os módulos de *Information Retrieval* e *Question Answering*, foram concebidas, adaptadas e validadas manualmente pelas autoras.

Na elaboração do relatório, a IA foi utilizada como apoio à revisão textual, reformulação de frases e melhoria da clareza e fluidez da escrita. A estrutura, conteúdo técnico, explicações metodológicas e decisões apresentadas resultam integralmente do trabalho desenvolvido pelo grupo.

O uso destas ferramentas teve, assim, um carácter complementar, contribuindo para uma escrita mais clara e para um processo de desenvolvimento mais eficiente, sem comprometer a integridade académica nem a autoria do trabalho.